

LLM-MODUL 1

WAS IST EIN LLM?





BJÖRN CYBERVIKING



LLM



WAS IST EIN LARGE LANGUAGE MODEL?

WORTE
VERSTEHEN
ZUSAMMENHÄNGE
ERKENNEN
ANTWORTEN
ERZEUGEN

1 DIE SUCHE

Man sagt, in dieser Höhle lebt ein weiser Runenmeister. Er kennt die Antworten auf schwierige Fragen.

DAS ORAKEL →

2 DIE FRAGE

Weiser, ich habe eine Frage:
Wie komme ich sicher über den Berg?

Eine gute Frage. Ich kenne viele Worte und Zusammenhänge. Ich werde dir eine Antwort geben.

3 DER WISSENSCHATZ

Ich denke an das, was ich gelernt habe. Worte, Bilder, Geschichten und Erfahrungen – all das ist in mir.

4 DIE ANTWORT ENTSTEHT

Ich bringe meine Gedanken in Worte. Schritt für Schritt – immer ein Wort nach dem anderen.

Du ...

5 SCHRITT FÜR SCHRITT

Jedes neue Wort basiert auf dem, was bereits da ist. So entsteht die gesamte Antwort – Stück für Stück in meinem Kopf.

6 DIE WEISSAGUNG

Hier ist deine Antwort:

„Du erreichst den Gipfel sicher, wenn du dem alten Pfad folgst.“

Wow! Du hast die Antwort also einfach gewusst?

7 NICHT EINE DATENBANK

Heißt das, du hast irgendwo eine Schriftrolle mit genau dieser Antwort gefunden?

Nein. Ich bin keine Datenbank. Ich habe keine fertigen Antworten gespeichert. Ich erzeuge sie aus dem, was ich gelernt habe, und den Zusammenhängen zwischen den Worten.

8 VIELE MÖGLICHKEITEN

Gibt es immer nur eine richtige Antwort?

Oft gibt es viele mögliche Antworten. Ich wähle die, die am besten zum Kontext passt. Deshalb können Antworten auch unterschiedlich ausfallen – und das ist normal.

MERKE:

Ein Large Language Model (LLM) verarbeitet Sprache und erzeugt daraus Schritt für Schritt eine Antwort. Es nutzt das, was es aus vielen Texten gelernt hat, um die nächsten Worte vorherzusagen. Es ist keine Datenbank – sondern ein Modell, das Sprache versteht und neue Texte erzeugen kann.





WISSEN
IN WÖRTERN
VERBINDET
WELTEN



WAS IST EIN LLM?

EIN EINFACHER EINBLICK IN DIE WELT DER KI

Wie aus vielen gelesenen Texten
neue Antworten entstehen.



FRAGEN
IDEEN
ANTWORTEN
NEUE
MÖGLICHKEITEN

1 DIE KURZE ANTWORT

Ein Large Language Model (LLM) ist ein KI-Modell, das menschliche Sprache versteht und daraus Schritt für Schritt eine Antwort erzeugt.

Kurz gesagt:
Ein LLM ist ein sehr
gut trainierter
Textverstehender und
Textvervollständiger.



2 WAS KANN EIN LLM?

- ✓ Fragen beantworten
- ✓ Texte zusammenfassen
- ✓ Ideen und Vorschläge liefern
- ✓ Texte umformulieren
- ✓ Code schreiben und erklären
- ✓ Inhalte analysieren
- ✓ Kreative Texte erstellen
- ✓ In vielen Sprachen kommunizieren

Ich helfe dir beim
Denken, Schreiben
und Problemlösen –
aber ich bin kein
Allwissender!



3 WIE FUNKTIONIERT ES IN EINFACHEN WÖRTERN?

Ein LLM hat während des Trainings sehr viele Texte gelesen und daraus gelernt, wie Wörter zusammenhängen. Es nutzt dieses Gelernte, um auf deine Eingabe eine passende Antwort zu erzeugen – Wort für Wort.

Ich habe nicht einfach
eine Antwort im Regal –
ich kombiniere, was ich
gelernt habe, zu etwas
Neuem.



4 DER WISSENSCHATZ

Während des Trainings wurde das Modell mit einer riesigen Menge an Texten gefüttert: Bücher, Webseiten, Artikel, Gespräche und vieles mehr. Es lernt dabei Muster, Zusammenhänge und Bedeutungen von Wörtern und Sätzen.



All dieses Wissen steckt nicht als einzelne Texte im Modell, sondern in gelernten Zusammenhängen.

5 VON DER EINGABE ZUR ANTWORT



Deine Eingabe
(Frage, Aufgabe, Text ...)



Das LLM
verarbeitet den Kontext
und erzeugt Schritt für
Schritt die nächsten Wörter.



Die Antwort
(entsteht Wort für Wort)

Ich nehme deine
Eingabe, denke
darüber nach – und
schreibe dann
meine Antwort
Stück für Stück.



6 WAS EIN LLM NICHT IST

- ✗ Keine klassische Datenbank
- ✗ Kein direkter Zugriff auf aktuelle Informationen (außer mit Tools)
- ✗ Kein Garant für immer korrekte Antworten
- ✗ Kein echtes Verständnis wie ein Mensch
- ✗ Kein Ersatz für Fachwissen oder gesunden Menschenverstand

Ich klinge manchmal sehr sicher –
aber ich kann auch Fehler machen.
Deshalb gilt: Immer kritisch denken
und wichtige Informationen prüfen!



7 TYPISCHE EINSATZGEBIETE

- 🗨️ Fragen & Antworten
- 📄 Texte schreiben und bearbeiten
- 📖 Zusammenfassen und Erklären
- 💡 Ideen entwickeln
- 🔗 Programmieren und Debuggen
- 🎓 Lernen und Unterricht
- ⚙️ Planung und Organisation
- 🌐 Übersetzungen
- 🔍 Analyse von Informationen

Ein LLM ist ein vielseitiges Werkzeug,
das in vielen Bereichen unterstützen kann.

8 EIN BLICK HINTER DIE KULISSEN

Ein LLM besteht aus vielen Milliarden Parametern, die während des Trainings angepasst werden. Es nutzt eine spezielle Architektur, den Transformer, um Zusammenhänge in Texten zu erkennen.

Die technischen Details sind
spannend – aber du musst
sie nicht alle kennen, um ein
LLM sinnvoll zu nutzen.

TRANSFORMER



9 DAS WICHTIGSTE IN EINEM SATZ

Ein LLM ist ein KI-Modell,
das auf Grundlage von
viel gelerntem Text
deine Eingabe versteht
und daraus Schritt für Schritt
eine passende Antwort erzeugt.



NEUGIER
SCHAFFT
ZUKUNFT!



MERKE:

- ✓ Ein LLM versteht und erzeugt Sprache auf Basis von gelerntem Wissen.
- ✓ Es kombiniert Gelernte Zusammenhänge zu neuen Texten.
- ✓ Es ist keine Datenbank und nicht immer korrekt.
- ✓ Es kann in vielen Bereichen unterstützen – wenn es verantwortungsvoll eingesetzt wird.



GUTE FRAGEN
BESSERE
ANTWORTEN
MEHR
MÖGLICHKEITEN

SI-LLM-01 – Was ist ein Large Language Model?

Björn und der Geist im Runenstein

1. Einordnung des Moduls

Large Language Models (LLMs) sind inzwischen Bestandteil zahlreicher Anwendungen. Sie können Texte analysieren, Fragen beantworten, Inhalte zusammenfassen, Informationen strukturieren und natürliche Sprache erzeugen.

Für Fachinformatiker Systemintegration ist dabei zunächst eine grundlegende Frage wichtig. Was ist ein Large Language Model technisch überhaupt? Ein LLM wird häufig als „künstliche Intelligenz“ oder als „KI, die Texte versteht“ bezeichnet. Diese Beschreibung ist für den Einstieg verständlich, reicht für eine technische Betrachtung jedoch nicht aus.

Ein Large Language Model ist ein maschinelles Lernmodell, das darauf trainiert wurde, sprachliche Muster aus sehr großen Mengen von Trainingsdaten zu erlernen. Es verarbeitet Texte nicht auf die gleiche Weise wie ein Mensch. Das Modell besitzt kein menschliches Verständnis von Sprache und keine eigene Vorstellung davon, was eine Aussage in der realen Welt bedeutet.

Stattdessen berechnet es auf Grundlage der bisherigen Eingabe, welche Fortsetzung einer Sequenz wahrscheinlich ist. Aus dieser vergleichsweise einfachen Grundidee entstehen durch große Modelle, umfangreiche Trainingsdaten und hohe Rechenleistung erstaunlich komplexe Fähigkeiten.

Für die Systemintegration ist deshalb nicht nur das Modell selbst relevant. Ein LLM ist Bestandteil eines Gesamtsystems aus beispielsweise:

- Modell,
- Recheninfrastruktur,
- Speicher,
- Schnittstellen,
- Anwendungen,
- Datenquellen,
- Benutzern und
- Sicherheitsmechanismen.

Die folgenden Module bauen auf diesem grundlegenden Verständnis auf.

2. Lernziele

- den Begriff Large Language Model (LLM) erklären
- den grundsätzlichen Zweck eines Sprachmodells beschreiben
- erklären, dass ein LLM sprachliche Muster aus Trainingsdaten erlernt
- den Begriff Token grundlegend einordnen
- erklären, dass ein LLM auf Basis einer Eingabe eine wahrscheinliche Fortsetzung berechnet
- zwischen einem LLM und einer klassischen Suchmaschine unterscheiden

- zwischen einem LLM und einer klassischen Datenbank unterscheiden
- erklären, warum die Größe eines Modells und seiner Trainingsdaten relevant ist
- grundlegende Bestandteile eines LLM-Systems benennen
- Training und Inference grundlegend unterscheiden
- erklären, warum eine überzeugend formulierte Antwort nicht automatisch korrekt sein muss

3. Didaktische Ausgangslage

Viele Menschen begegnen einem LLM zunächst über eine Chatoberfläche.

Sie schreiben eine Frage und erhalten wenige Sekunden später eine sprachlich passende Antwort.

Dadurch entsteht leicht der Eindruck, dass im Hintergrund ein System sitzt, das die Frage wie ein Mensch versteht, Informationen aus einem Gedächtnis abrufen und anschließend eine Antwort formuliert. Für eine technische Betrachtung ist dieses Modell jedoch zu einfach. Ein LLM erzeugt seine Ausgabe auf Grundlage statistisch erlernter Zusammenhänge innerhalb von Sprache.

Ein vereinfachtes Beispiel:

Der Wikinger betrat das ...

Ein Sprachmodell kann aus seinen erlernten Mustern ableiten, dass beispielsweise

Langhaus

eine wahrscheinliche Fortsetzung sein könnte.

Es „weiß“ dabei nicht im menschlichen Sinne, was ein Wikinger, ein Langhaus oder das Betreten eines Gebäudes ist. Es berechnet Wahrscheinlichkeiten für mögliche nächste Bestandteile der Eingabe. Genau dieses Prinzip bildet die Grundlage für die später behandelte Next-Token-Prediction.

4. Was bedeutet „Large Language Model“?

Large

„Large“ beschreibt, dass solche Modelle im Vergleich zu früheren Sprachmodellen sehr umfangreich sein können.

Dabei geht es insbesondere um:

- die Anzahl der Modellparameter,
- die Größe der Trainingsdaten,
- die benötigte Rechenleistung,
- die daraus entstehenden Fähigkeiten.

Die Bezeichnung „large“ bedeutet dabei nicht einfach, dass die Datei des Modells groß ist.

Language

Das Modell wurde darauf ausgelegt, sprachliche Sequenzen zu verarbeiten. Dabei können neben natürlicher Sprache auch andere strukturierte Textformen verarbeitet werden, beispielsweise:

- Quellcode,
- Konfigurationsdateien,
- Tabelleninhalte,
- Markup,
- Protokollauszüge.

Die grundlegende Verarbeitung erfolgt dabei über die Darstellung dieser Inhalte als Tokens.

Model

Ein LLM ist ein mathematisches Modell. Es besteht vereinfacht gesagt aus einer großen Menge erlernter Parameter, die während des Trainings angepasst wurden. Diese Parameter enthalten nicht einfach eine klassische Datenbank mit gespeicherten Antworten. Das Modell hat vielmehr statistische Zusammenhänge gelernt, die es bei der Verarbeitung neuer Eingaben verwendet.

5. Was ist ein Sprachmodell?

Ein Sprachmodell beschreibt Wahrscheinlichkeiten für sprachliche Sequenzen. Vereinfacht kann man sich die Aufgabe so vorstellen:

Die Burg steht auf dem ...

Mögliche Fortsetzungen wären beispielsweise:

Berg
Hügel
Felsen

Das Modell berechnet für mögliche nächste Tokens unterschiedliche Wahrscheinlichkeiten. Vereinfacht:

Berg → 0,42
Hügel → 0,18
Felsen → 0,11
Meer → 0,03
...

Das Modell wählt anschließend auf Grundlage seiner Berechnung ein Token aus. Danach wird dieses Token Bestandteil des bisherigen Textes und das Modell berechnet erneut die möglichen nächsten Tokens. Damit entsteht Schritt für Schritt eine Antwort.

6. Was ist ein Token?

Ein LLM verarbeitet Text nicht einfach als vollständige Wörter. Der Text wird zunächst in kleinere Einheiten zerlegt. Diese Einheiten werden Tokens genannt.

Ein Token kann beispielsweise sein:

- ein vollständiges Wort,
- ein Teil eines Wortes,
- ein Satzzeichen,

- oder eine andere gelernte Textsequenz.

Vereinfacht:

„Der Wikinger kommt.“


könnte beispielsweise in mehrere Tokens zerlegt werden. Die genaue Zerlegung hängt vom verwendeten Tokenizer und Modell ab.

Wichtig ist zunächst nur:

Das LLM arbeitet nicht direkt mit menschlichen Wörtern, sondern mit Tokens. Diese Tokens werden anschließend in eine für das Modell verarbeitbare numerische Darstellung überführt.

7. Vom Text zur Modellantwort

Die Verarbeitung lässt sich für den Einstieg stark vereinfacht darstellen:



Das Modell erzeugt also nicht zwingend eine komplette Antwort in einem einzigen Schritt. Es erzeugt die Ausgabe Schritt für Schritt. Genau deshalb wird im nächsten Modul die Next-Token-Prediction genauer betrachtet.

8. LLM ist nicht gleich Datenbank

Ein häufiger Denkfehler besteht darin, ein LLM als eine riesige Datenbank zu betrachten. Eine Datenbank speichert Informationen in strukturierten Datensätzen.

Beispielsweise:

Benutzer:
Name: Müller
Abteilung: IT
Telefon: 1234

Ein LLM funktioniert grundsätzlich anders.

Es speichert Wissen nicht einfach als einzelne Datensätze, die bei einer Anfrage wieder ausgelesen werden. Während des Trainings werden die Modellparameter angepasst. Dadurch entstehen statistische Repräsentationen sprachlicher Zusammenhänge. Das bedeutet gleichzeitig: Eine überzeugende Antwort ist keine Garantie dafür, dass die darin enthaltenen Informationen korrekt sind. Ein LLM kann eine sprachlich sehr plausible, aber sachlich falsche Aussage erzeugen.

9. LLM ist nicht gleich Suchmaschine

Auch eine Suchmaschine arbeitet grundsätzlich anders.

Eine Suchmaschine sucht Informationen in einem Index und liefert passende Treffer zurück. Ein LLM erzeugt dagegen eine Antwort auf Grundlage seiner Modellberechnung.

Vereinfacht:

Suchmaschine:

Suchanfrage



Index



Treffer

LLM:

Eingabe



Tokenisierung



Modell



Wahrscheinlichkeiten



generierte Ausgabe

Moderne Anwendungen können beide Ansätze miteinander verbinden. Genau daraus entsteht beispielsweise Retrieval-Augmented Generation (RAG).

Dieses Thema wird später in SI-LLM-06 behandelt.


10. Was befindet sich hinter einem LLM?

Ein LLM existiert in einer realen IT-Umgebung nicht einfach als „magischer Chat“. Für den Betrieb werden verschiedene Komponenten benötigt.


Vereinfacht:

Benutzer





Je nach System kommen weitere Komponenten hinzu:




Damit wird bereits deutlich, warum das Thema für Fachinformatiker Systemintegration relevant ist. Ein LLM ist nicht nur ein Algorithmus. Es muss bereitgestellt, angebunden, abgesichert, überwacht und betrieben werden.

11. Training und Inference

Training


Beim Training lernt das Modell aus großen Mengen von Trainingsdaten. Dabei werden die Modellparameter schrittweise angepasst.

Vereinfacht:



Inference

Bei der Inference wird das bereits trainierte Modell verwendet, um eine konkrete Eingabe zu verarbeiten und eine Ausgabe zu erzeugen.



Die Unterscheidung ist für die Systemintegration wichtig, weil Training und Betrieb eines Modells sehr unterschiedliche Anforderungen an Infrastruktur und Ressourcen stellen.


12. Praxisbezug für Fachinformatiker Systemintegration

Ein Fachinformatiker muss nicht selbst ein LLM entwickeln, um mit LLM-Systemen arbeiten zu können.


Relevant sind beispielsweise:

- Bereitstellung von Rechenressourcen,
- Netzwerkverbindungen,
- API-Anbindungen,
- Speicher,
- Identitäten und Berechtigungen,
- Monitoring,
- Protokollierung,
- Datensicherheit,
- Verfügbarkeit,
- Backup und Wiederherstellung,
- Integration in bestehende Anwendungen.

Ein Unternehmen kann beispielsweise einen internen KI-Assistenten betreiben. Aus Sicht der Systemintegration entsteht daraus eine Infrastruktur:



Später können weitere Komponenten hinzukommen:



Damit wird aus einem einfachen Chatbot ein komplexes IT-System.

13. Typische Denkfehler

„Das LLM weiß die Antwort.“

Ein LLM berechnet eine Ausgabe auf Grundlage seiner erlernten Muster. Eine plausible Antwort ist nicht automatisch eine korrekte Antwort.

„Das Modell speichert das Wissen wie eine Datenbank.“

Ein LLM ist keine klassische Datenbank. Die während des Trainings erlernten Informationen sind in der Struktur und den Parametern des Modells repräsentiert.

„Das LLM versteht Sprache wie ein Mensch.“

Ein LLM kann Sprache sehr leistungsfähig verarbeiten, besitzt aber kein menschliches Verständnis der Welt.

„Das LLM sucht einfach im Internet.“

Ein LLM benötigt nicht grundsätzlich eine Internetverbindung. Websuche oder externe Datenquellen müssen technisch angebunden werden.

„Ein LLM ist nur Software.“

Für den produktiven Betrieb werden neben dem Modell weitere Infrastruktur- und Sicherheitskomponenten benötigt.

14. Zusammenfassung

Ein Large Language Model ist ein maschinelles Lernmodell zur Verarbeitung und Erzeugung sprachlicher Sequenzen. Es verarbeitet Texte über Tokens und erzeugt seine Ausgabe schrittweise auf Grundlage berechneter Wahrscheinlichkeiten.

Ein LLM ist dabei weder eine klassische Datenbank noch automatisch eine Suchmaschine. Für den praktischen Einsatz wird ein LLM in eine technische Umgebung integriert. Diese kann neben dem Modell selbst unter anderem Anwendungen, APIs, Rechenressourcen, Datenquellen, Authentifizierung und Monitoring enthalten. Für Fachinformatiker Systemintegration ist deshalb nicht nur das Verständnis des Modells wichtig, sondern auch das Verständnis seiner technischen Einbindung.

15. MERKE

Ein LLM ist kein Mensch und keine klassische Datenbank.

Ein LLM verarbeitet Text als Tokens und erzeugt seine Ausgabe Schritt für Schritt.

Eine sprachlich überzeugende Antwort ist nicht automatisch eine sachlich richtige Antwort.

Ein produktives LLM-System besteht aus mehr als nur dem Modell.

16. Lerninhaltskontrolle

Aufgabe 1

Was bedeutet die Abkürzung LLM?

Aufgabe 2

Was versteht man unter einem Token?

Aufgabe 3

Wie erzeugt ein LLM vereinfacht eine Antwort?

Aufgabe 4

Warum ist ein LLM keine klassische Datenbank?

Aufgabe 5

Was ist der Unterschied zwischen Training und Inference?

Aufgabe 6

Warum kann eine sprachlich überzeugende Antwort trotzdem falsch sein?

Aufgabe 7

Nenne mindestens fünf Komponenten oder Bereiche, die neben dem Modell für den Betrieb eines LLM-Systems relevant sein können.

Aufgabe 8

Transferaufgabe: Ein Unternehmen möchte einen internen KI-Assistenten für seine Mitarbeiter bereitstellen. Welche technischen Komponenten müssen aus Sicht eines Fachinformatikers Systemintegration grundsätzlich betrachtet werden?

17. Lösungsschlüssel

Aufgabe 1

LLM steht für Large Language Model.

Aufgabe 2

Ein Token ist eine vom Modell verarbeitete Texteinheit. Je nach Tokenizer kann es sich beispielsweise um ein Wort, einen Wortteil oder ein Satzzeichen handeln.

Aufgabe 3

Das Modell verarbeitet die Eingabe, berechnet Wahrscheinlichkeiten für mögliche nächste Tokens und erzeugt daraus schrittweise die Ausgabe.

Aufgabe 4

Ein LLM speichert Informationen nicht wie eine klassische Datenbank in strukturierten Datensätzen. Wissen wird während des Trainings in den Modellparametern beziehungsweise deren statistischen Zusammenhängen repräsentiert.

Aufgabe 5

Training bezeichnet das Lernen beziehungsweise Anpassen der Modellparameter anhand von Trainingsdaten. Inference bezeichnet die Nutzung eines bereits trainierten Modells zur Verarbeitung konkreter Eingaben.

Aufgabe 6

Das Modell optimiert seine Ausgabe auf sprachlich plausible Fortsetzungen. Sprachliche Plausibilität garantiert daher nicht die sachliche Richtigkeit.

Aufgabe 7

Beispiele: Recheninfrastruktur, Speicher, Netzwerk, Anwendung, API, Authentifizierung, Berechtigungen, Monitoring, Logging und Datensicherheit.

Aufgabe 8

Unter anderem müssen Anwendung, Authentifizierung, Netzwerk, LLM-Service, Rechenressourcen, Modell, Datenquellen, Berechtigungen, Monitoring und Sicherheitsmechanismen betrachtet werden.

18. Curriculum-Zuordnung

Das Modul bildet die technische Grundlage für die weitere Beschäftigung mit Large Language Models innerhalb der Systemintegration.

Im Mittelpunkt stehen insbesondere folgende Kompetenzbereiche:

- grundlegende Funktionsweise moderner IT-Systeme verstehen,
- technische Komponenten eines Gesamtsystems erkennen,
- Anwendungen und Dienste in eine bestehende IT-Infrastruktur einordnen,
- technische Abhängigkeiten erkennen,
- Anforderungen an Betrieb, Sicherheit und Verfügbarkeit beschreiben,
- technische Zusammenhänge verständlich erklären.

Das Modul schafft die Grundlage für die folgenden Themen Tokenisierung, Next-Token-Prediction, Context, Training, Inference und die Integration von LLM-Systemen.